



НИУ ВШЭ, Нижегородский филиал

Факультет информатики, математики и компьютерных наук

Оптимизация качества облачного видеостриминга в условиях ограниченности вычислительных ресурсов с применением классических эвристических методов и подходов на основе машинного обучения

Выпускная квалификационная работа - бакалаврская работа

Студент

Даниил Денисович Паршин

Руководитель

П. А. Колданов

Консультант

В. Г. Жислина

Нижний Новгород, 2026



Проблема

Ограничение качества в облачном стриминге не сводится к выбору битрейта

- Облачный видеоконвейер делит CPU между детекцией, кодированием, сетью и служебной логикой.
- ABR управляет качеством во времени: битрейт, разрешение, профиль. Но внутри кадра качество остается распределенным эвристиками кодека.
- Для пользователя ошибки неравноценны: текст, лица и фактуры одежды заметнее, чем однородный фон.

Область	Почему важна
Text	читаемость интерфейса, субтитров, документов
Face	субъективно значимые человеческие области
Cloth	высокочастотные фактуры, где артефакты заметны
Background	источник бюджета для перераспределения

Проблема работы

Нужен способ передать кодировщику, какие области кадра важнее, не выходя за CPU-бюджет и размер потока.



Конкретная задача

Проверяется связка «детектор ROI → политика кодирования → качество»

Что нужно построить

- CPU-first слой IDet для Text, Face и Cloth ROI.
- Контракт ROI: геометрия, тип, приоритет, ограничение площади, `qoffset`.
- Эксперимент baseline vs ROI-aware HEVC при сопоставимом размере.

Ограничение	Практический смысл
p99 < 10 ms	tail latency важнее среднего времени
size ratio ≈ 1	выигрыш не покупается ростом файла
area cap	ROI не должна занять почти весь кадр
portable ONNX	runtime не зависит от Python и GPU

Граница вывода

Эксперимент кодирования покадровый: он изолирует spatial ROI-effect, но не заменяет полный end-to-end видеотест.



Обзор подходов

Почему модель детекции сама по себе не решает задачу видеокачества

Подход	Что дает	Что остается нерешенным
ABR / rate adaptation	Управляет битрейтом, разрешением и профилем потока во времени.	Не говорит кодировщику, что внутри одного кадра текст важнее фона.
Global PSNR/SSIM/VMAF	Удобны для общей оценки кодека и регрессий.	Усредняют кадр; локальная деградация ROI может быть скрыта фоном.
ROI/saliency coding	Позволяет передавать кодировщику spatial priority.	Требуется надежного ROI extraction, area cap, qoffset-policy и temporal stability.
Detector-only mAP	Проверяет качество ML-компонента.	Не учитывает CPU, p99, постобработку и фактический эффект в libx265.


Позиция ВКР

Оценивать нужно не отдельную mAP, а системный контур: ROI-детекция формирует side data, кодировщик перераспределяет биты, метрики проверяют локальный эффект при почти том же размере потока.



Предлагаемый подход

IDet отделяет runtime-детекцию от политики кодирования




Text/Face/Cloth ROI объединяются в геометрию; кодировочный слой добавляет тип, приоритет, area cap и `qoffset`.



Textured ROI

YOLO26s: +0.019 mAP50-95, но 20.5 GFLOPs против 5.2




Выбор YOLO26n: 0.818 mAP50-95, 5.2 GFLOPs и 9.3 MB против 0.837, 20.5 GFLOPs и 36.4 MB у YOLO26s.



CPU-исполнение IDet

Рабочая точка выбирается по p99 и качеству покрытия ROI



Каждая точка соответствует одной runtime-конфигурации grid-search.


Режим	p99, ms	Recall	Area F1
Text	8.032	0.886	0.788
Face	7.553	0.916	0.922
Cloth	9.230	0.920	0.871

- Text: выше recall, чтобы не пропустить читаемые области.
- Face: лучший баланс Area F1 и p99.
- Cloth: ближе к 10 ms, потому что YOLO тяжелее.



Протокол кодирования

Режим `match_baseline` исключает объяснение «файл стал больше»



Режим	Кадры	Baseline	Size ratio	qoff.
Text	3000	CRF 32	1.0036	−1/4
Face	3000	CRF 32	1.0058	−1/5
Cloth	2696	CRF 32	1.0029	−1/10

HEVC: `libx265, preset medium`. Baseline идет без ROI side data; ROI-aware получает side data через `addroi`.


Baseline и ROI-aware ветки декодируются обратно в PNG и сравниваются с оригиналом.

Global оценивает весь кадр, ROI-сноп — кропы ROI, Background показывает цену перераспределения качества при фиксированном размере.



Результаты: локальное качество ROI

Text и Face дают сильный эффект; Cloth положителен, но сложнее




ROI-crop improvement: качество измеряется внутри кропов областей интереса.

Численно: Text +3.331 dB / +4.451 VMAF; Face +3.284 dB / +5.857 VMAF; Cloth +0.547 dB / +0.449 VMAF. Positive share: 0.90–1.00.



Результаты: цена перераспределения

Фон ухудшается контролируемо, потому что общий размер почти фиксирован



ROI-only PSNR растет, background PSNR снижается: это ожидаемый эффект фиксированного бюджета.

Вывод: global/background-метрики фиксируют цену перераспределения, но ROI-weighted PSNR остается положительным для всех трех типов ROI.



Ограничения и дальнейшая работа

Что доказано сейчас и что требуется для production-video

Подтверждено

- IDet формирует ROI в реалистичном CPU-бюджете для отдельных веток.
- YOLO26n является рациональным lightweight-кандидатом для Cloth ROI.
- ROI side data через `addroi/libx265` дает устойчивый локальный выигрыш на FHD-кадрах.
- Size ratio около 1.0 исключает объяснение результата ростом файла.

Не закрыто в рамках ВКР

- temporal smoothing и tracking ROI между кадрами;
- GOP-aware настройка и межкадровое предсказание;
- end-to-end live latency вместе с кодировщиком и сетью;
- планировщик частоты запуска трех ROI-веток.

Следующий шаг

Перенести покадровый результат на видеокорпус:
стабилизировать ROI во времени, измерить flicker/битрейт/latency и сравнить с production baseline.



Финальный вывод

Что доказано работой

ROI-aware слой не заменяет ABR и rate-control, а добавляет кодировщику пространственный управляющий сигнал. При почти неизменном размере потока качество управляемо перераспределяется к областям, где цена артефактов выше.

Engineering

IDet возвращает ROI-геометрию в CPU-бюджете.

ML

YOLO26n выбран как lightweight textured ROI detector.

Video quality

Text, Face и Cloth ROI получают локальный выигрыш.

Главная формулировка

Качество не «становится лучше везде». Оно перераспределяется туда, где пользователь сильнее замечает деградацию: текст, лица и визуально насыщенные фактуры.



Спасибо за внимание

Готов ответить на вопросы

Даниил Денисович Паршин
НИУ ВШЭ, Нижний Новгород

2026